

Software Analytics Canvas

Project: Modelo preditivo para inferência em paradas cardíacas

<div> 1. Question</div> <div><i>What is it that we want to know about the software / processes / usage / organization / etc.?</i></div> <div><ul style="list-style-type: none">• É possível diferenciar dados de um paciente que teve uma parada cardíaca de alguém que não?• Caso seja possível, podemos aprender este comportamento e, por meio deste, inferir novas paradas cardíacas apenas olhando para os dados referentes ao paciente e ao seu estado clínico?</div>	<div> 2. Data Sources</div> <div><i>Which data can possibly answer our question? What information do we need?</i></div> <div><ul style="list-style-type: none">• Dados relacionados a “quem é o paciente?” e extraídos de exames dos pacientes como (idade, colesterol, pressão sanguínea, etc...)• Os dados necessitam possuir um variável rótulo para que seja possível diferenciar em que circunstâncias é identificada a ocorrência de uma parada cardíaca, assim como o seu oposto.</div>	<div> 3. Heuristics</div> <div><i>Which assumptions do we want to make to simplify the answer to our question?</i></div> <div><ul style="list-style-type: none">• Entender características que podem descrever uma parada cardíaca• Encontrar possíveis correlações dos dados com o nosso alvo• Se os resultados forem positivos podemos criar nosso modelo preditivo e realizar os testes</div>	<div> 4. Validation</div> <div><i>What results do we expect from our analysis, how are they reviewed and presented in an understandable way?</i></div> <div><p>Esperamos que seja possível obter boas correlações dos dados</p><p>Com boas correlações, se torna plausível a utilização de algoritmos de machine learning para aprendizagem de padrões existentes nos dados</p></div>	
<div> 5. Implementation</div> <div><i>How can we implement the analysis step by step and in a comprehensible way?</i></div> <div><p>A implementação da análise se dará pelo uso da metodologia já consolidada no mercado: CRISP-DM (Cross Industry Standard Process for Data Mining)</p><p>Os passos a se seguir serão os seguintes:</p><ul style="list-style-type: none">• Business understanding: nesta etapa, devemos entender o cenário em que nosso estudo se encontra.• Data understanding: uma vez que tenhamos os dados em mãos, devemos entendê-los para que seja possível saber qual a qualidade do dado que será estudado e quais transformações serão necessárias.• Data preparation: fase em que devemos realizar os tratamentos e devidas transformações que foram devidamente mapeadas durante a fase de entendimento.• Modeling: aqui, será onde daremos início a criação do modelo de aprendizagem de máquina. Devemos, então, testar diversos modelos e técnicas para consolidarmos uma sólida base de comparação.• Evaluation: após criamos uma base sólida de modelos, é chegada a hora de validarmos qual modelo melhor resolve nosso problema de negócio, o qual estamos estudando.• Deployment: neste estudo, o deployment será dado pelas respostas das perguntas que foram feitas inicialmente e previamente documentadas na parte escrita deste trabalho.</div>		<div> 6. Results</div> <div><i>What are the main insights from our analysis?</i></div> <div><ul style="list-style-type: none">• Em desempenhos positivos, é possível observar como algoritmos de machine learning podem agregar valor como ferramentas analíticas para profissionais da saúde.<p>Estes, podem observar detalhes e comportamentos que um ser Humano pode não perceber por mais que esteja atento.</p></div>		<div> 7. Next Steps</div> <div><i>What follow-up actions can we derive from the findings? Who or what do we need to address next?</i></div> <div><ul style="list-style-type: none">• Como próximos passos, visto a melhoria da performance do modelo escolhido e também a inclusão de profissionais da saúde que possam estar interessados na pesquisa e queiram ajudá-la a evoluir.</div>